SIMULAHUB · MÓDULO 1 · DIA 5 · 07/11

Do CFD aos dados e à Inteligência Artificial

Como aprender com as simulações?

Profª. Drª. Rita de Cássia dos Anjos – Universidade Federal de São Carlos (UFSCar)

Ciência de dados, aprendizado de máquina e scikit-learn aplicados a 600 simulações hemodinâmicas

ONDE CHEGAMOS

O último degrau do curso

Dia 1	Dia 2	Dia 3	Dia 4	Dia 5
Física	**Equações**	**Simulação**	**Visualização**	**Dados e IA**

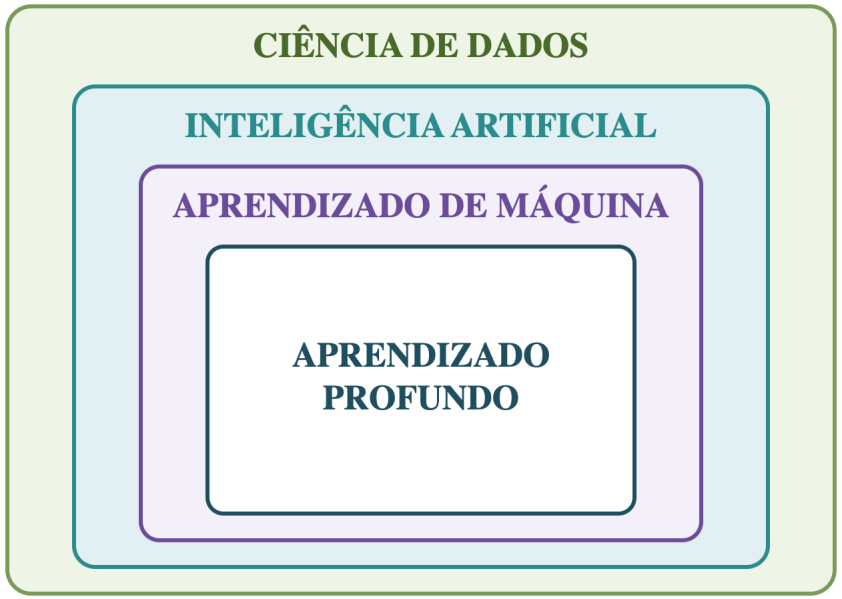
Já sabemos simular um vaso e interpretar o resultado. Mas cada simulação responde a **um** caso. E se tivermos **centenas** de simulações? Que padrões aparecem? Dá para **prever** o resultado de um caso novo sem simular de novo?

ROTEIRO

O que veremos hoje

1	**Ciência de dados, IA e aprendizado de máquina**	o que é cada um
2	**Cada simulação é um experimento**	features e target
3	**Explorar os dados**	análise exploratória
4	**Tipos de aprendizado**	classificação e regressão
5	**Treino, teste e overfitting**	como não se enganar
6	**Scikit-learn na prática**	regressão e Random Forest
7	**Classificar lesões**	regressão logística, matriz de confusão
8	**Surrogate models, limites e ética**	IA a serviço da física

Ciência de dados, IA, aprendizado de máquina



Ciência de dados: extrair conhecimento de dados, combinando estatística, computação e conhecimento da área. *Carro: coletar e analisar os dados dos sensores*

Inteligência artificial (IA): máquinas que executam tarefas que normalmente exigem inteligência humana. *Carro: dirigir.*

Aprendizado de máquina (ML): algoritmos que aprendem padrões a partir de dados, sem regras programadas uma a uma. *Carro: reconhecer um pedestre ou uma placa.*

Aprendizado profundo: ML com redes neurais de muitas camadas (imagens, voz, texto). *Carro: as redes neurais que analisam as imagens da câmera, quadro a quadro, para identificar pedestres e sinais de trânsito.*

EM PALAVRAS SIMPLES

No nosso vaso: ciência de dados é todo o processo, das simulações às conclusões; IA é decidir se uma lesão é grave; ML é aprender isso com exemplos simulados.

Olhar para o passado ou prever o futuro

Análise de dados

Descreve e explica o que já aconteceu: tabelas, gráficos, tendências.

“Nas 600 simulações, quando a queda de pressão passou de 10 mmHg?”

Ciência de dados

Usa os dados para prever ou decidir sobre casos novos.

“Qual será a queda de pressão em uma estenose que nunca simulamos?”

Papel	O que faz	No nosso curso
Engenheiro de dados	disponibiliza os dados	quem roda e organiza as simulações
Analista de dados	interpreta para a decisão	quem lê os resultados e conclui
Cientista de dados	transforma dados em modelos preditivos	quem treina o modelo de ML

Cada simulação é um experimento que gera uma linha de tabela



Features (características, variáveis de entrada): o que nós escolhemos ao montar a simulação.

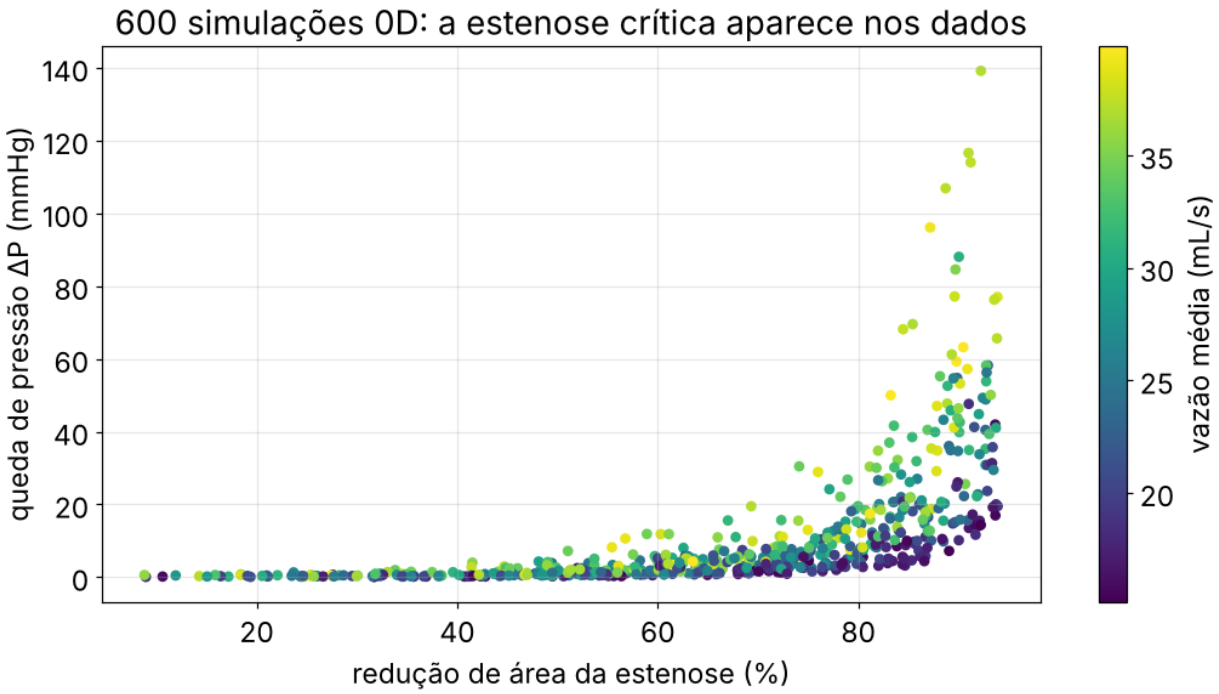
Target (alvo, variável de saída): o que a simulação calcula e queremos aprender a prever.

Nosso conjunto de dados: 600 simulações 0D

Variável	Papel	Faixa nas simulações
redução de área da estenose	feature	0 a 94%
vazão média de entrada	feature	15 a 40 mL/s
raio da ilíaca	feature	0,30 a 0,50 cm
rigidez da parede (E·h)	feature	2 a 8 × 10^5 dyn/cm
resistência de saída	feature	5 000 a 16 000 dyn·s/cm^5
queda de pressão ΔP	target (regressão)	0,1 a 140 mmHg
lesão significativa (Pd/Pa < 0,80)	target (classificação)	15% dos casos

Modelo da bifurcação aorta → ilíacas do Dia 3, com valores sorteados para cada simulação. As 600 simulações levaram cerca de 10 segundos.

Antes de qualquer modelo: olhar os dados



Análise exploratória: gráficos e estatísticas simples para entender os dados antes de modelar.

O que os dados mostram:

- até ~60% de área, quase nenhuma queda de pressão;
- acima de ~80%, a queda dispara: a **estenose crítica**;
- com mais vazão (amarelo), a queda é maior.

4 · TIPOS DE APRENDIZADO

Três formas de uma máquina aprender

Supervisionado

aprende com exemplos que têm resposta

Tarefas: classificação e regressão

Exemplo: prever ΔP a partir das entradas

Não supervisionado

encontra padrões sem resposta conhecida

Tarefas: agrupamento, redução de dimensão

Exemplo: agrupar simulações parecidas

Por reforço

aprende por tentativa, com recompensas

Tarefas: agentes, jogos, robótica

Exemplo: (pouco usado em hemodinâmica)

EM PALAVRAS SIMPLES

Supervisionado é como estudar com o gabarito: o aluno vê muitas questões já resolvidas e aprende a resolver as novas. Hoje usamos só esse tipo.

Regressão ou classificação?

Regressão

Prever um **número** contínuo.

$\Delta P = ?$ mmHg

Algoritmos: regressão linear, Random Forest.

Classificação

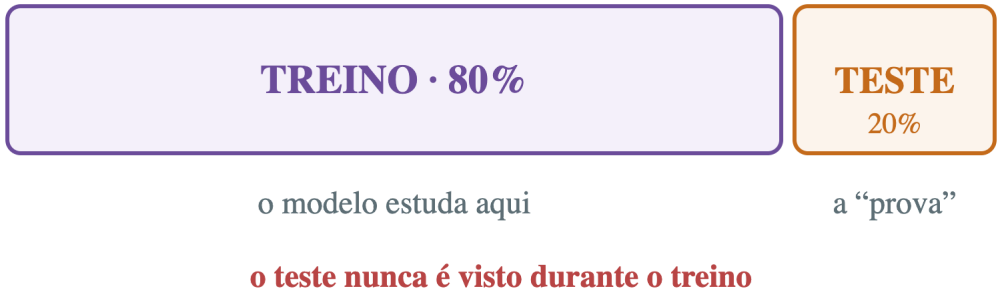
Prever uma **categoria**.

lesão significativa? sim / não

Algoritmos: regressão logística, SVM, Random Forest.

A mesma tabela serve para os dois: muda só a coluna-alvo.

Separar os dados: estudar com uma lista, fazer a prova com outra



Treino: o algoritmo ajusta seus parâmetros a esses exemplos.

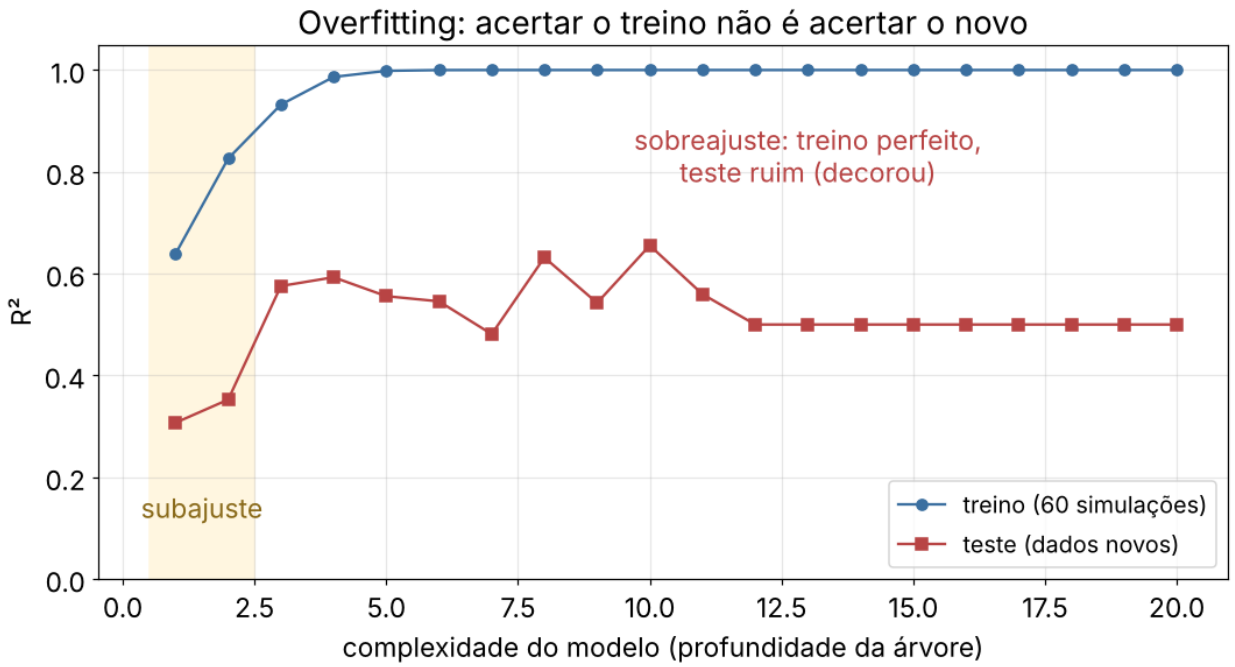
Validação: escolhe entre configurações do modelo (opcional).

Teste: avaliação final com dados nunca vistos: mede a **generalização**.

EM PALAVRAS SIMPLES

Se a prova tiver as mesmas questões da lista de exercícios, a nota não mede o aprendizado. É por isso que o teste fica guardado.

Overfitting: decorar não é aprender



Uma árvore de decisão treinada com só 60 simulações:

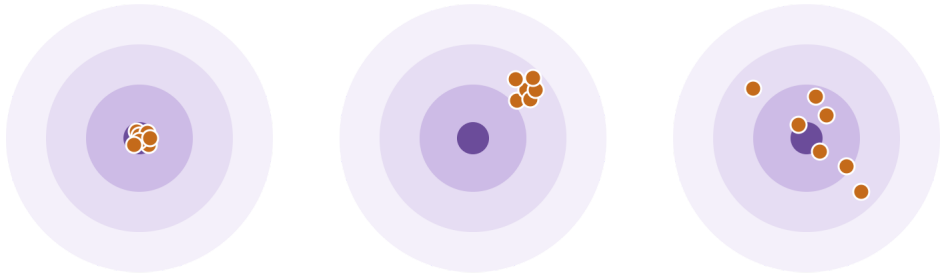
Simples demais (à esquerda): erra no treino e no teste: **subajuste** (underfitting).

Complexa demais (à direita): acerta 100% do treino, mas só ~50% do teste: **sobreajuste** (overfitting).

EM PALAVRAS SIMPLES

O aluno que decora as respostas da lista tira 10 na lista e vai mal na prova.

Viés e variância: dois jeitos de errar



baixo viés, baixa variância | alto viés, baixa variância | baixo viés, alta variância

Viés: erro por simplificar demais; erra sempre para o mesmo lado.

Variância: erro por ser sensível demais aos dados de treino; muda muito com pequenas mudanças.

$$\text{erro total} = \text{viés}^2 + \text{variância} + \text{ruído}$$

Viés nos dados: se só simulamos certas geometrias ou certos pacientes, o modelo herda essa limitação.

Scikit-learn: a caixa de ferramentas de ML em Python

Biblioteca **livre** e de código aberto, construída sobre NumPy, SciPy e Matplotlib.

Importada como **sklearn**; instalação: pip install scikit-learn (já vem no Colab).

Todo modelo segue a mesma receita:

fit(X, y) → predict(X_novo)

Módulo	Para quê	Exemplo
sklearn.model_selection	dividir dados, validação cruzada	train_test_split
sklearn.preprocessing	padronizar e codificar	StandardScaler
sklearn.linear_model	modelos lineares	LinearRegression, LogisticRegression
sklearn.ensemble	combinação de modelos	RandomForestRegressor
sklearn.metrics	avaliar	r2_score, confusion_matrix
sklearn.pipeline	encadear passos	Pipeline

O código completo cabe em poucas linhas

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import r2_score

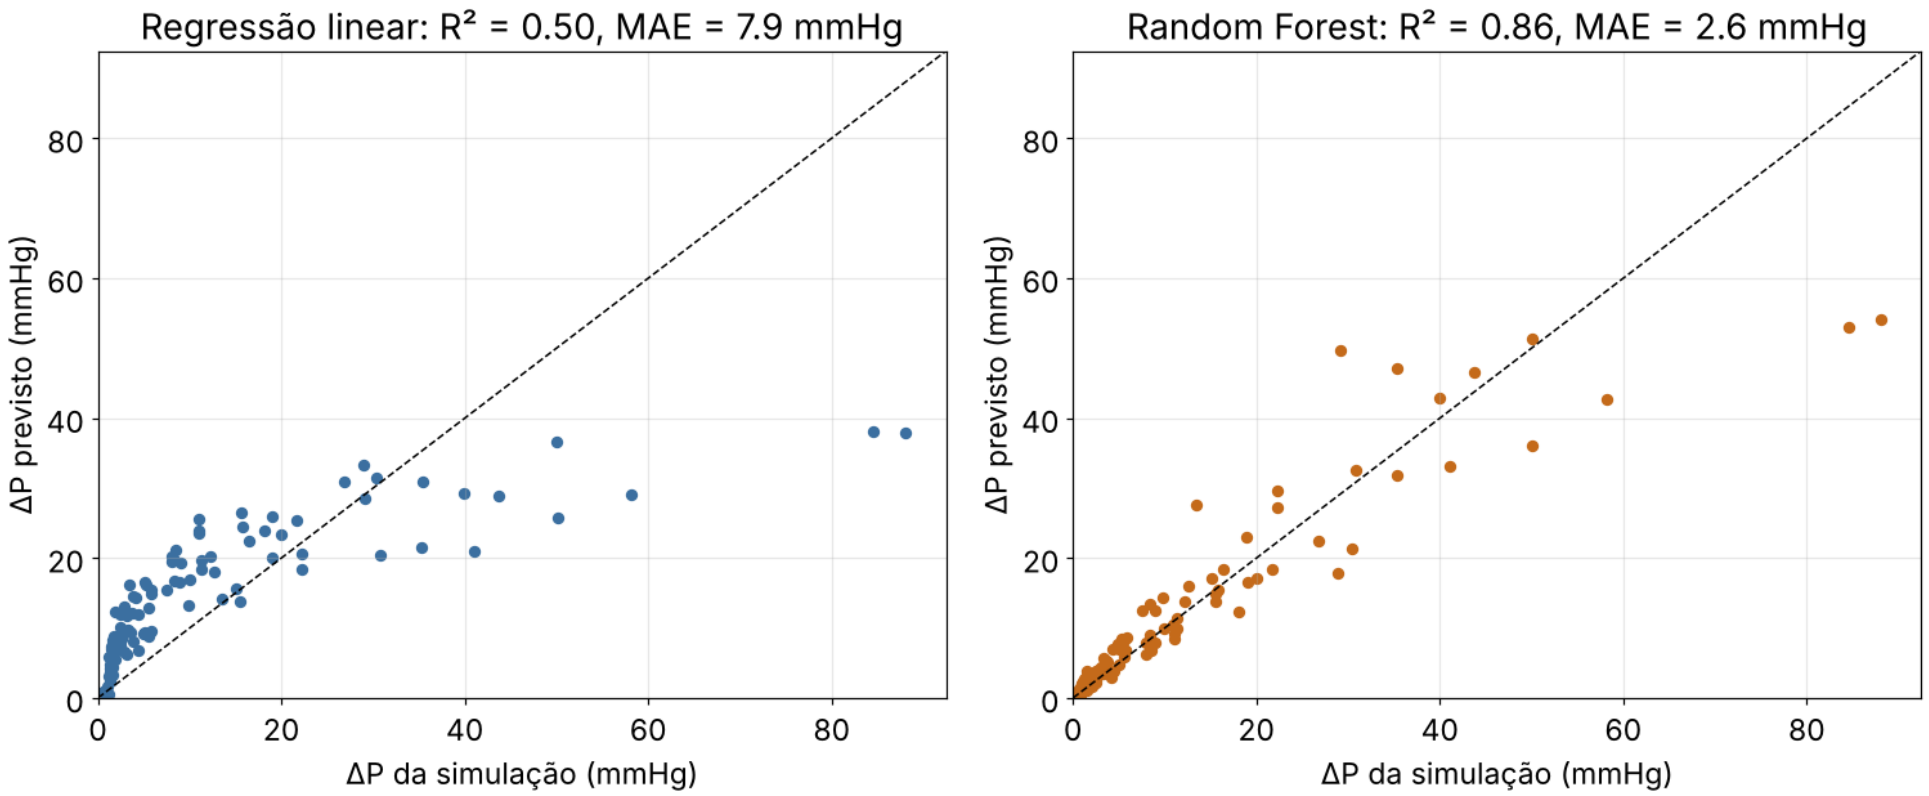
dados = pd.read_csv('simulacoes.csv')       # 600 linhas
X = dados[['reducao_area','vazao_media','raio_iliaca',
           'rigidez_EH','R_saida']]        # features
y = dados['deltaP_mmHg']                   # target

X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, random_state=42)  # 80/20

modelo = RandomForestRegressor(n_estimators=300)
modelo.fit(X_tr, y_tr)                     # aprender
print(r2_score(y_te, modelo.predict(X_te)))  # avaliar
```

1. Ler a tabela de simulações (pandas).
2. Separar features (X) e target (y).
3. Dividir em treino e teste.
4. Escolher o modelo e treinar com **fit**.
5. Prever o teste com **predict** e medir.

Prevendo a queda de pressão: dois modelos



6 · SCIKIT-LEARN

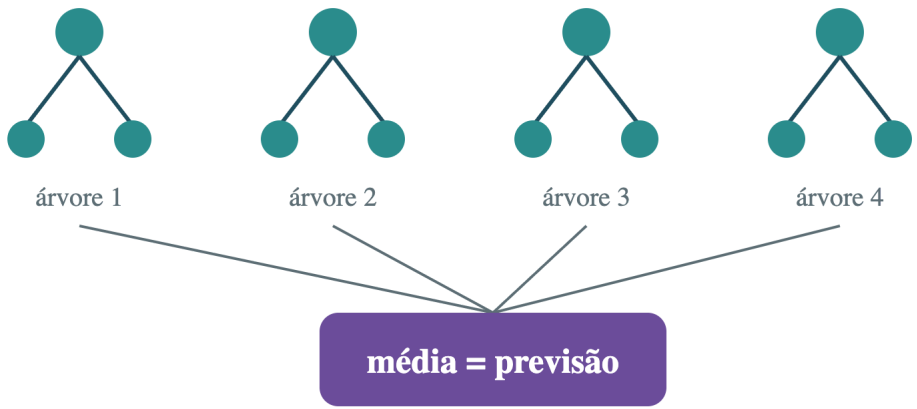
Como medir o erro de uma regressão

Métrica	O que mede	Regressão linear	Random Forest
MAE (erro absoluto médio)	quanto o modelo erra, em média, em mmHg	7,9 mmHg	2,6 mmHg
RMSE (raiz do erro quadrático médio)	como o MAE, mas pune mais os erros grandes	11,0 mmHg	5,8 mmHg
R^2 (coeficiente de determinação)	fração da variação explicada (1 = perfeito)	0,50	0,86

EM PALAVRAS SIMPLES

MAE de 2,6 mmHg: em média, a previsão da Random Forest erra a queda de pressão por 2,6 mmHg. Bom para triagem; para decidir um tratamento, ainda seria preciso simular (ou medir).

Random Forest: a sabedoria da multidão



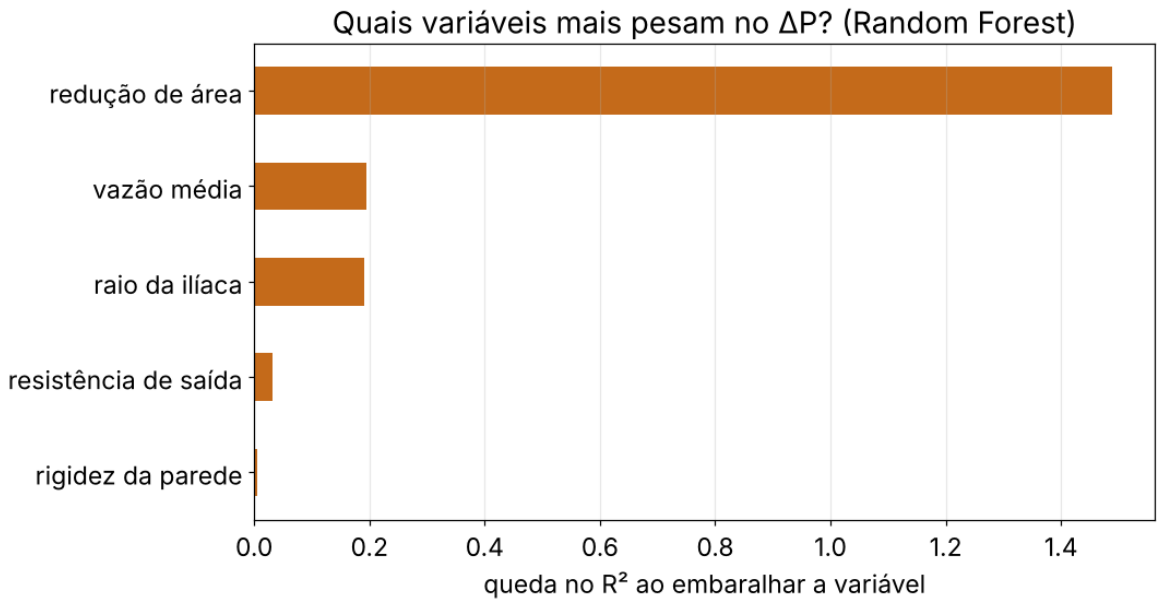
Árvore de decisão: uma sequência de perguntas sim/não sobre as entradas (“a redução é maior que 80%?”) até chegar a uma resposta.

Random Forest (floresta aleatória): centenas de árvores, cada uma treinada com uma amostra diferente dos dados. A previsão final é a **média** delas.

EM PALAVRAS SIMPLES

Perguntar a 300 especialistas, cada um com experiência um pouco diferente, e tirar a média: erros individuais se cancelam.

Quais variáveis mais pesam? E isso faz sentido físico?



Importância por permutação: embaralhamos uma coluna e vemos quanto o modelo piora. Se piora muito, a variável é importante.

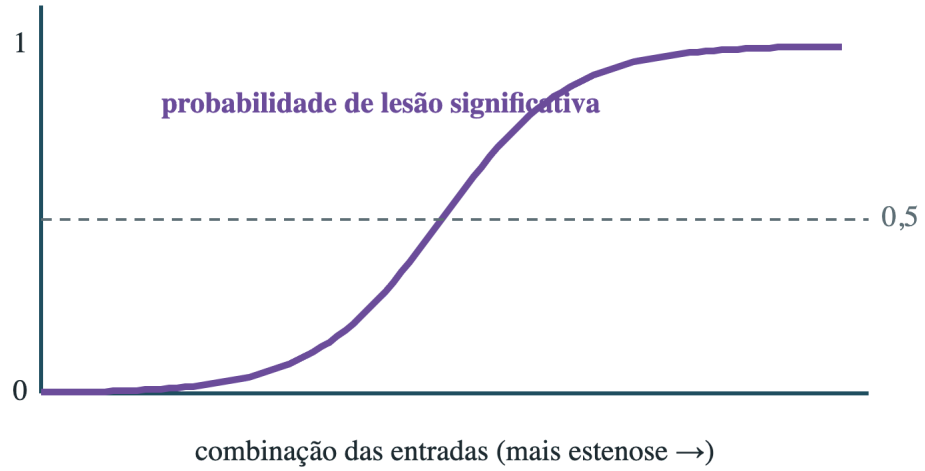
Redução de área domina: é a lesão (Young e Tsai).

Vazão e raio vêm depois: $\Delta P \propto Q^2$ e depende da área.

Rigidez ≈ 0: no 0D ela muda a pulsação, não a perda média.

7 · CLASSIFICAR LESÕES

A lesão é significativa? Regressão logística



Alvo: **Pd/Pa < 0,80** (o critério do FFR, Dia 3).

A **regressão logística** não responde só “sim” ou “não”: ela dá uma **probabilidade** entre 0 e 1, pela curva em forma de S (sigmoide).

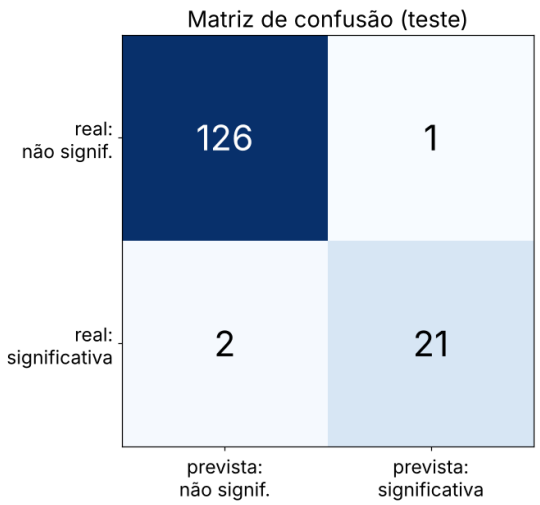
Acima de 0,5, o modelo diz “significativa”. Esse limiar pode ser ajustado.

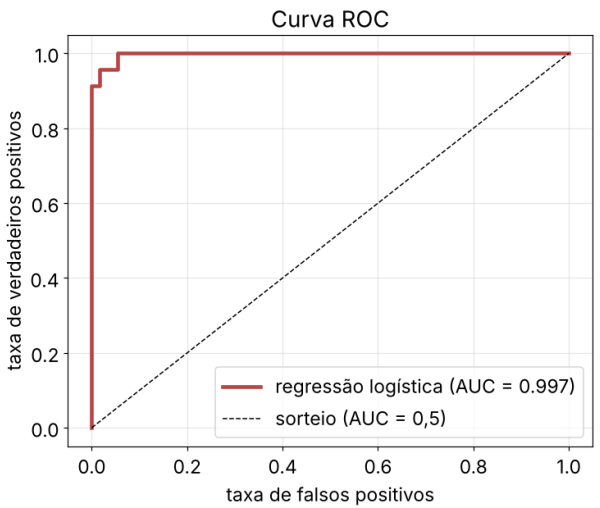
EM PALAVRAS SIMPLES

Em vez de “é grave”, o modelo diz “há 92% de chance de ser grave”. Isso ajuda quem decide.

Como saber se o classificador é bom

(Receiver Operating Characteristic)





98%

acurácia: acertos no total

95%

precisão: dos que ele chamou de graves, quantos eram

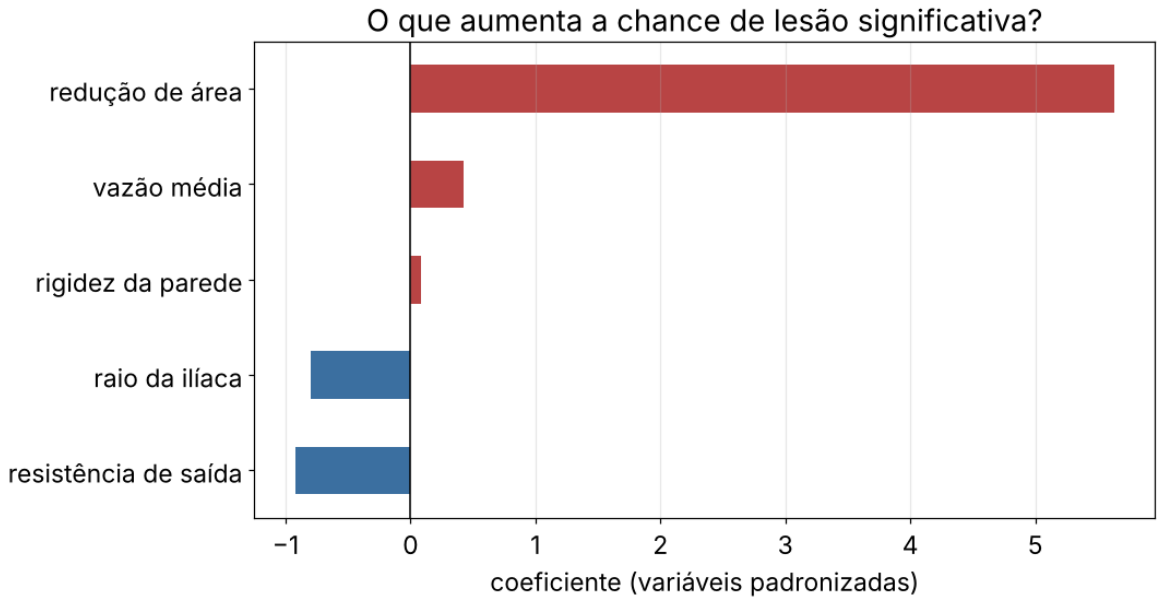
91%

revocação: dos graves, quantos ele encontrou

0,997

AUC: área sob a curva ROC

O que o modelo aprendeu: lendo os coeficientes



Vermelho (positivo): aumenta a chance de lesão significativa.

Azul (negativo): diminui.

Mais estenose e mais vazão → mais risco.

Vaso maior → menos risco: a mesma obstrução deixa mais área livre.

Mais resistência a jusante → menos fluxo pela lesão → menos queda.

8 · SURROGATE MODELS

Um modelo que imita a simulação

Surrogate model

Um modelo de ML treinado com simulações que responde, em milissegundos, o que a simulação levaria muito mais tempo para calcular.

(*surrogate* = substituto)

Quanto se ganha

	tempo
1 simulação 0D	~13 ms
10 000 previsões da Random Forest	~0,5 s
1 simulação 3D	horas

EM PALAVRAS SIMPLES

No 0D o ganho é pequeno, porque ele já é rápido. O valor aparece no 3D: treinar com algumas centenas de simulações de horas e depois explorar milhares de cenários em segundos.

8 · LIMITES

O modelo aprende com as simulações; não substitui a física

Extrapolação

Fora da faixa de treino (por exemplo, vazão de 80 mL/s ou outra artéria), o modelo pode dar qualquer resposta. A física continua valendo; o modelo, não.

Herda os erros

Se as simulações têm hipóteses fortes (0D, parede rígida, sangue newtoniano), o modelo aprende essas mesmas limitações.

Sem garantia física

Nada obriga o modelo a conservar massa ou energia. Ele pode prever, por exemplo, uma queda de pressão negativa.

Regra de ouro: comparar sempre **CFD × ML** em casos de teste, e usar a IA como **ferramenta complementar** à modelagem física.

8 · PERSPECTIVAS

Para onde a área caminha

PINNs

Physics-informed neural networks, redes neurais informadas pela física: a rede é treinada para obedecer às equações (Navier–Stokes, conservação de massa), não só aos dados.

Gêmeos digitais

Uma cópia virtual de um paciente ou de um órgão, atualizada com os dados dele, para testar tratamentos antes de aplicá-los.

Exames sem cateter

Já existem exames que estimam o Pd/Pa a partir de uma tomografia, combinando segmentação da imagem, CFD e IA.

EM PALAVRAS SIMPLES

A tendência é juntar o melhor dos dois mundos: a física garante coerência; os dados e a IA garantem velocidade e adaptação a cada paciente.

8 · CICLO DE VIDA

O ciclo de um projeto de IA (CRISP-DM)

1
Compreensão do problema
a estenose limita o fluxo?

2
Dados
600 simulações 0D

3
Preparação
tabela, checar valores

4
Modelagem
Random Forest, logística

5
Avaliação
métricas no teste

6
Implantação
ferramenta de triagem + monitorar

EM PALAVRAS SIMPLES

CRISP-DM é um roteiro padrão para projetos de dados: entender o problema, os dados, prepará-los, modelar, avaliar e implantar. É um ciclo: a avaliação muitas vezes manda voltar a uma etapa anterior.

8 · ÉTICA

IA responsável em saúde

Princípio	Significado	No nosso contexto
Transparência	entender por que o modelo decide	ler coeficientes e importâncias
Justiça (fairness)	não discriminar grupos	dados que representem idades, sexos e anatomias
Responsabilidade	alguém responde pela decisão	o modelo apoia; quem decide é o profissional
Privacidade	proteger dados pessoais	imagens e laudos seguem a LGPD
Beneficência	promover o bem-estar	usar para triagem, não para negar cuidado

O CURSO EM UMA LINHA

Como a geometria de um vaso influencia o fluxo sanguíneo?

Física
pressão, Bernoulli

Equações
viscosidade, Navier–Stokes

Simulação
0D, 1D, 2D, 3D

Visualização
campos, WSS

Dados e IA
ML, scikit-learn

Cada dia respondeu à pergunta com uma ferramenta nova. Hoje, os dados de muitas simulações mostraram o mesmo padrão: a estenose crítica e o peso da vazão e do raio.

TARDE · 2 H COM O TUTOR WILLIAN

Do dataset ao modelo

Atividades

- Leitura do dataset com pandas
- Organização e visualização dos dados
- Separação treino/teste
- Treinamento de regressão ou Random Forest
- Predição de ΔP
- Comparação CFD × ML e limitações

Resultado esperado do dia

Entender como dados produzidos por CFD podem ser usados em modelos simples de aprendizado de máquina e como a IA pode atuar como ferramenta complementar à modelagem física.

RESUMO

O que levar do Dia 5

Conceito	No nosso exemplo	Ideia-chave
Features e target	entradas → saídas da simulação	cada simulação = uma linha
Supervisionado	aprende com exemplos resolvidos	regressão e classificação
Treino e teste	train_test_split	o teste nunca é visto no treino
Overfitting	treino ótimo, teste ruim	decorar não é aprender
Regressão	Random Forest: $R^2 = 0,86$	MAE = 2,6 mmHg
Classificação	regressão logística: AUC = 0,997	revocação 91%: atenção aos falsos negativos
Surrogate model	ML que imita a simulação	complementa, não substitui a física

GLOSSÁRIO

Os termos do aprendizado de máquina

Termo	Em palavras simples
Dataset	a tabela de dados: uma linha por experimento ou simulação
Feature	variável de entrada (o que escolhemos)
Target	variável de saída (o que queremos prever)
Treino / teste	dados para aprender / dados guardados para avaliar
Overfitting	o modelo decora o treino e erra em dados novos
Underfitting	o modelo é simples demais e erra em tudo
Hiperparâmetro	um ajuste do modelo escolhido antes do treino (ex.: número de árvores)
Surrogate model	modelo de ML que imita uma simulação, muito mais rápido

GLOSSÁRIO

Os termos das métricas e ferramentas

Termo	Em palavras simples
MAE / RMSE	erro médio da previsão, na unidade da variável
R^2	fração da variação explicada pelo modelo (1 = perfeito)
Matriz de confusão	tabela de acertos e erros de um classificador
Precisão / revocação	dos que o modelo apontou, quantos eram; dos que eram, quantos ele achou
Curva ROC / AUC	desempenho para todos os limiares; 0,5 = sorteio, 1 = perfeito
Scikit-learn	biblioteca livre de ML em Python (sklearn)
Random Forest	média de centenas de árvores de decisão
Regressão logística	classificador que dá uma probabilidade, pela curva sigmoide

FIM DO MÓDULO 1

Física → Simulação → Visualização → Dados → IA

Obrigada! A seguir, o Módulo 2 aprofunda o caminho que começa antes da simulação: imagens médicas, segmentação e inteligência artificial na saúde.

Profª. Drª. Rita de Cássia dos Anjos · UFSCar